Trabalho Autoencoders

Prof: Paulo Cotta

Data de entrega: 09/12/2020

Nota: 30 pts

Roteiro do trabaho

- O trabalho deve ser explicado célula por célula
- Não é necessário chegar em um processo ótimo, o razoável já é muito bom
- O trabalho deve ser feito usando o modelo não supervisionado Autoencoder
- Havendo dúvida, pode perguntar ao professor, em qualquer horário que for necessário

Alunos

- João Marcelo
- Matheus Reis
- Matheus Sena
- Thiago Costa
- Ygor Oliveira

O que deve ser feito

Recomendação de Conteúdo com Filtragem Colaborativa

O princípio da Filtragem Colaborativa é utilizar a informação das interações que ocorrem entre os usuários e os conteúdos para que, de forma coletiva, essa informação seja útil para inferir as preferências dos indivíduos.

O que devemos fazer é criar um modelo que seja capaz de gerar Scores dos determinados produtos que possam recomendar para os usuários. Exemplo dessa funcionalidade é recomendações do Netfix, Amazon, Google Maps e entre outros.

O dataset está contido na pasta [data], avaliem às variáveis.

OBS.: Pode usar códigos da internet e fique a vontade para pesquisar mais sobre Autoencoders.

Imports

In [16]:

```
# imports

import numpy as np
import pandas as pd
import tensorflow as tf
import matplotlib.pyplot as plt
from tensorflow.keras import Sequential
from tensorflow.keras.layers import Input, Dense, Dropout
from tensorflow.keras.optimizers import Adam
from tensorflow.keras.backend import clear_session
```

In [2]:

```
tf.__version__
```

Out[2]:

```
'2.2.0'
```

Dataset

In [3]:

```
# dataset com dados dos jogos e o total de horas e jogadores
articles_df = pd.read_csv('./data/articles_df.csv')
articles_df.head()
```

Out[3]:

	content_id	game	total_users	total_hours
0	0	007 Legends	1	1.7
1	1	0RBITALIS	3	4.2
2	2	1... 2... 3... KICK IT! (Drop That Beat Like a...	7	27.0
3	3	10 Second Ninja	6	11.9
4	4	10,000,000	1	4.6

In [4]:

```
# quantidade de horas jogadas (ou só comprado quando horas == 1) por jogador
interactions_full_df = pd.read_csv('./data/interactions_full_df.csv')
interactions_full_df.head()
```

Out[4]:

	user_id	content_id	game	hours	view
0	0	226	Alien Swarm	5.9	1
1	0	846	Cities Skylines	145.0	1
2	0	972	Counter-Strike	1.0	1
3	0	978	Counter-Strike Source	1.0	1
4	0	1125	Day of Defeat	1.0	1

In [5]:

```
# Top 5 jogadores com mais horas
interactions_full_df.sort_values('hours', ascending=False).head(5)
```

Out[5]:

	user_id	content_id	game	hours	view
69958	1627	1328	Dota 2	10443.0	1
83764	2079	1328	Dota 2	7766.0	1
37124	852	1328	Dota 2	6965.0	1
62122	1398	1328	Dota 2	6016.0	1
52203	1154	3792	Sid Meier's Civilization V	6014.0	1

In [6]:

```
# Quantidade de horas jogadas por jogador ou jogo apenas adquirido
rating = pd.read_csv('./data/rating.csv', names=['user_id', 'game', 'type', 'ho
rating.head()
```

Out[6]:

	user_id	game	type	hours	none
0	151603712	The Elder Scrolls V Skyrim	purchase	1.0	0
1	151603712	The Elder Scrolls V Skyrim	play	273.0	0
2	151603712	Fallout 4	purchase	1.0	0
3	151603712	Fallout 4	play	87.0	0
4	151603712	Spore	purchase	1.0	0

In [7]:

```
# dataset de treino e de test
df_train = pd.read_csv('./data/interactions_train_df.csv')
df_test = pd.read_csv('./data/interactions_test_df.csv')
```

Construção dos dados

In [8]:

```
# matriz de correlação entre jogadores e jogos jogados
dataset = pd.pivot(df_train, index='user_id', columns='content_id', values='vie
dataset.fillna(0, inplace=True)
print(f'Shape do dataset de treino {dataset.shape}')
```

```
Shape do dataset de treino (3757, 4862)
```

In [9]:

```
x_train = dataset.values
y_train = dataset.values
```

In [10]:

```
# tipos de valores no dataset
dataset.describe()
```

Out[10]:

content_id	0	1	2	3	5	6	
count	3757.000000	3757.000000	3757.000000	3757.000000	3757.000000	3757.000000	375
mean	0.000266	0.000266	0.001331	0.001065	0.002129	0.000532	
std	0.016315	0.016315	0.036461	0.032616	0.046102	0.023069	
min	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	
25%	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	
50%	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	
75%	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	
max	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	

8 rows × 4862 columns

Model

In [11]:

```
clear_session()
```

In [12]:

```
model = Sequential(name='autoencoder')

# camada de entrada
model.add(Input((4862,)))
model.add(Dense(512, activation='selu'))
model.add(Dense(256, activation='selu'))
model.add(Dropout(0.8))

# camada de saída
model.add(Dense(512, activation='selu'))
model.add(Dense(4862, activation='linear'))
```

In [13]:

```
# compilando o modelo
model.compile(optimizer=Adam(lr=0.0001), loss='mse')
```

In [14]:

```
# desenho do modelo
model.summary()
```

```
Model: "autoencoder"
_________________________________________________________________
Layer (type)                 Output Shape              Param #
=================================================================
dense (Dense)                (None, 512)               2489856
_________________________________________________________________
dense_1 (Dense)              (None, 256)               131328
_________________________________________________________________
dropout (Dropout)            (None, 256)               0
_________________________________________________________________
dense_2 (Dense)              (None, 512)               131584
_________________________________________________________________
dense_3 (Dense)              (None, 4862)              2494206
=================================================================
Total params: 5,246,974
Trainable params: 5,246,974
Non-trainable params: 0
_________________________________________________________________
```

Treinamento

In [15]:

```
history = model.fit(x=x_train, y=y_train,
                    epochs=50,
                    shuffle=True,
                    validation_split=0.1)
```

```
Epoch 1/50
106/106 [==============================] - 4s 36ms/step - loss: 0.02
51 - val_loss: 0.0033
Epoch 2/50
106/106 [==============================] - 4s 39ms/step - loss: 0.01
50 - val_loss: 0.0027
Epoch 3/50
106/106 [==============================] - 4s 40ms/step - loss: 0.01
08 - val_loss: 0.0024
Epoch 4/50
106/106 [==============================] - 4s 35ms/step - loss: 0.00
87 - val_loss: 0.0022
Epoch 5/50
106/106 [==============================] - 3s 32ms/step - loss: 0.00
74 - val_loss: 0.0021- ETA:
Epoch 6/50
106/106 [==============================] - 3s 32ms/step - loss: 0.00
66 - val_loss: 0.0020
Epoch 7/50
```

Métricas do treinamento

In [23]:

```
fig, ax = plt.subplots(1, 1, figsize=(8, 6))

ax.plot(history.history['loss'], label='loss')
ax.plot(history.history['val_loss'], label='val_loss')

ax.legend()
plt.show()
```

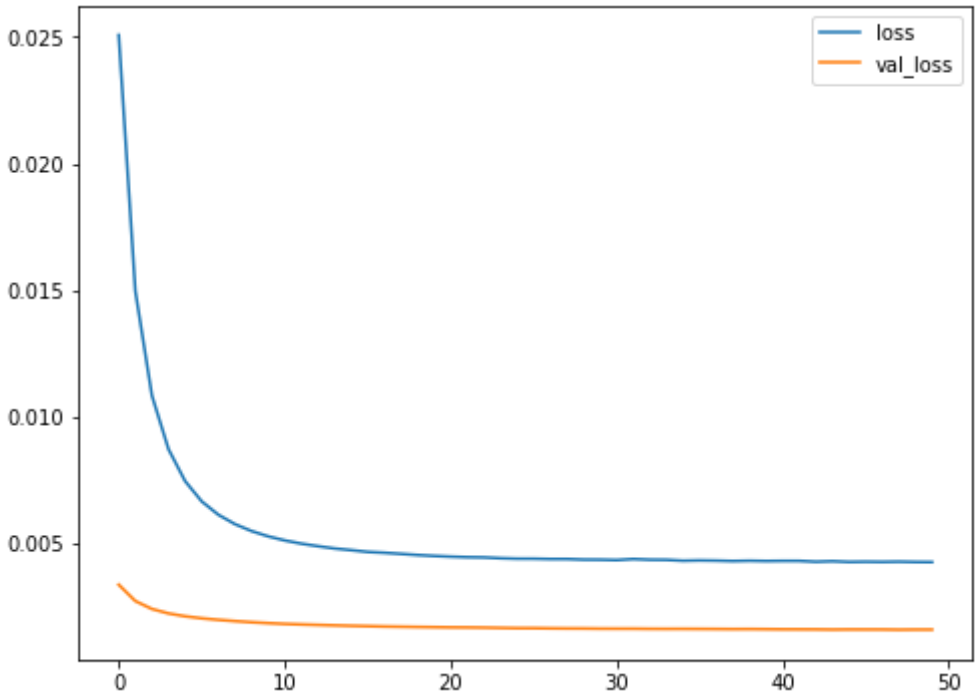

Sistema de recomendação

In [33]:

```
matriz_recomendacao = model.predict(x_train)
matriz_recomendacao = pd.DataFrame(matriz_recomendacao, index=dataset.index, co
```

In [56]:

```
def recomendacao(id_usuario, matriz_recomendacao, matriz_jogos, k=5):
    # scores do jogador
    usuario_jogos_recomendacao = matriz_recomendacao.loc[id_usuario].values

    # dataset com jogador, jogo e score em ordem de melhor recomendação
    usuario_jogos_recomendacao_scores = pd.DataFrame({'score': usuario_jogos_re
                                                      index=list(matriz_recomend
    usuario_jogos_recomendacao_scores = usuario_jogos_recomendacao_scores.join(
    usuario_jogos_recomendacao_scores = usuario_jogos_recomendacao_scores.sort_

    return usuario_jogos_recomendacao_scores.head(k)
```

Resultados

O jogador 1200 gosta de jogar jogos com história medieval, o que condiz com a recomendação

In [72]:

```
# jogos que ele joga
interactions_full_df[interactions_full_df['user_id'] == 1200].head(5)
```

Out[72]:

	user_id	content_id	game	hours	view
53749	1200	173	Age of Empires II HD Edition	11.3	1
53750	1200	174	Age of Empires II HD The Forgotten	1.0	1
53751	1200	275	Anno 1404	25.0	1
53752	1200	276	Anno 1404 Venice	36.0	1
53753	1200	440	Banished	36.0	1

In [62]:

```
# jogos recomendados
recomendacao(1200, matriz_recomendacao, articles_df)
```

Out[62]:

	score	game
4328	0.594614	The Elder Scrolls V Skyrim
4329	0.436620	The Elder Scrolls V Skyrim - Dawnguard
4330	0.423038	The Elder Scrolls V Skyrim - Dragonborn
4331	0.420610	The Elder Scrolls V Skyrim - Hearthfire
1667	0.418422	Fallout New Vegas

O jogador 3700 gosta de jogar jogos de FPS, o que condiz com a recomendação

In [73]:

```
# jogos que ele joga
interactions_full_df[interactions_full_df['user_id'] == 3700].head(5)
```

Out[73]:

	user_id	content_id	game	hours	view
114655	3700	418	BLOCKADE 3D	1.0	1
114656	3700	975	Counter-Strike Global Offensive	71.0	1
114657	3700	976	Counter-Strike Nexon Zombies	2.0	1
114658	3700	1679	Far Cry 3	4.9	1
114659	3700	1886	Gear Up	1.0	1

In [70]:

```
# jogos recomendados
recomendacao(3700, matriz_recomendacao, articles_df)
```

Out[70]:

	score	game
975	0.454469	Counter-Strike Global Offensive
4750	0.424096	Unturned
4221	0.155830	Team Fortress 2
1328	0.142575	Dota 2
976	0.127830	Counter-Strike Nexon Zombies